

AgriPredict

*Optimisation du rendement céréalier par fusion des données climatiques et
pédologiques*

Rapport technique

Certificat en Intelligence Artificielle

Réalisé par : Diene Alioune Badara Médoune

Dépôt GitHub : github.com/AliouneBadaraMedouneDiene/AgriPredict

1. Description du problème

Le changement climatique rend les saisons agricoles de plus en plus difficiles à prévoir. Pour aider les agriculteurs à mieux s'organiser, les conseillers agricoles ont besoin d'outils simples qui donnent une idée du rendement attendu avant même la récolte.

Ce projet répond à ce besoin en simulant un outil destiné à des conseillers agricoles : à partir des caractéristiques du sol (nutriments, pH) et des conditions climatiques (température, humidité, pluie), l'outil estime le rendement attendu d'une culture, exprimé en kilogrammes par hectare (kg/ha).

L'objectif technique est donc de construire un modèle de régression, c'est-à-dire un modèle qui prédit une valeur continue (un nombre), et non une catégorie.

2. Description des données

Le projet utilise le jeu de données "Crop Recommendation Dataset", disponible sur Kaggle sous licence CC0 (domaine public). Il contient 2200 lignes réparties sur 22 cultures différentes, avec exactement 100 lignes par culture.

Chaque ligne décrit un ensemble de conditions de culture à travers 7 variables numériques :

- N, P, K : teneurs du sol en azote, phosphore et potassium
- temperature : température moyenne (°C)
- humidity : humidité relative de l'air (%)
- ph : pH du sol
- rainfall : pluviométrie (mm)

ainsi qu'une variable catégorielle label indiquant la culture concernée (riz, maïs, banane, café...).

Le dataset ne présentait aucune valeur manquante et aucun doublon, ce qui a évité une étape de nettoyage lourde.

2.1 Signification des variables

Pour éviter toute ambiguïté, le tableau ci-dessous détaille chaque variable du dataset : son unité et ce qu'elle représente concrètement.

Variable	Unité	Signification
N	kg/ha (ou mg/kg)	Teneur du sol en azote, un nutriment essentiel à la croissance des plantes.
P	kg/ha (ou mg/kg)	Teneur du sol en phosphore, favorise le développement des racines.
K	kg/ha (ou mg/kg)	Teneur du sol en potassium, renforce la résistance de la plante.
temperature	°C	Température moyenne de l'air pendant la période de culture.
humidity	%	Humidité relative de l'air.
ph	sans unité (échelle 0-14)	Acidité ou alcalinité du sol ; 7 est neutre, en dessous c'est acide, au-dessus c'est basique.
rainfall	mm	Quantité de pluie tombée sur la période de culture.
label	catégorie	Nom de la culture concernée (riz, maïs, banane, café, etc.).
yield_kg_ha	kg/ha	Rendement de la culture : quantité récoltée par hectare. Variable cible à prédire (générée synthétiquement, voir

Variable	Unité	Signification
		section 2.2).

Tableau 1 — Description des variables du dataset

2.2 Une limite importante : l'absence de variable de rendement

Ce dataset a été conçu à l'origine pour de la classification : il permet de recommander une culture à partir de conditions données, pas de prédire un rendement. Il ne contient donc aucune colonne de rendement réel.

Pour répondre à l'objectif du projet, une variable `yield_kg_ha` a donc été générée de façon synthétique, à partir d'une combinaison pondérée des variables du sol et du climat, avec un peu de hasard ajouté pour représenter la variabilité naturelle du terrain :

$$yield_kg_ha = N \times 15 + P \times 10 + K \times 10 + rainfall \times 5 + humidity \times 8 + \text{bruit aléatoire}$$

Les poids utilisés (15, 10, 10, 5, 8) sont arbitraires et n'ont pas de validité agronomique précise : ils ont été choisis uniquement pour obtenir une variable cible cohérente (plus de nutriments et de pluie donnent un rendement plus élevé), utilisable pour l'exercice de modélisation. Cette limite est assumée et détaillée en section 7.

Après génération, le rendement simulé varie entre environ 1060 et 5560 kg/ha, avec une moyenne proche de 2870 kg/ha, ce qui donne une variable exploitable et sans valeur négative.

3. Méthodologie

Le pipeline suit les étapes classiques d'un projet de machine learning :

- Analyse exploratoire (EDA) : étude des distributions, des corrélations et des valeurs aberrantes
- Prétraitement : encodage de la culture, séparation des variables explicatives et de la cible
- Séparation train/test : 80 % des données pour l'entraînement, 20 % pour le test
- Modélisation : entraînement de deux modèles à comparer
- Évaluation : mesure des performances avec trois métriques (MAE, RMSE, R²)
- Analyse des erreurs : recherche de cultures où le modèle se trompe le plus

3.1 Analyse exploratoire

La première étape a consisté à regarder la forme de chaque variable à l'aide d'histogrammes.




Figure 1 — Distribution des variables numériques

Les variables N, P, K et humidity présentent plusieurs pics distincts (distribution multimodale), ce qui s'explique par la diversité des besoins propres à chacune des 22 cultures du dataset. La variable rainfall est étalée vers la droite : beaucoup de valeurs se concentrent entre 50 et 150 mm, avec une traîne de valeurs plus rares jusqu'à 300 mm. La variable cible yield_kg_ha suit une forme globalement régulière, sans valeur aberrante visible.

La matrice de corrélation permet ensuite de voir quelles variables sont le plus liées au rendement.




Figure 2 — Matrice de corrélation entre les variables

Le potassium (K) est la variable la plus corrélée au rendement simulé (0.71), suivi du phosphore (P, 0.55) et de l'azote (N, 0.47). L'humidité (0.38) et la pluie (0.27) ont une influence plus modérée. La température et le pH,

qui n'entrent pas dans la formule de simulation, ont une corrélation quasi nulle, ce qui confirme que la construction du rendement s'est bien déroulée comme prévu. On note aussi une corrélation forte entre P et K (0.74), signe d'une redondance d'information entre ces deux variables — sans conséquence pour les modèles à base d'arbres utilisés ici.

Le sujet demandait en particulier d'observer la relation entre la pluie et le rendement :




Figure 3 — Relation entre pluviométrie et rendement

Le nuage de points montre une tendance globalement croissante, cohérente avec la corrélation de 0.27 mesurée précédemment. La forte dispersion verticale à pluviométrie identique montre que la pluie seule n'explique qu'une petite partie du rendement : les nutriments du sol (surtout K, P et N) ont une influence plus déterminante.

3.2 Détection des valeurs aberrantes

Les boîtes à moustaches (boxplots) ont permis de repérer les valeurs extrêmes de chaque variable.




Figure 4 — Boîtes à moustaches des variables explicatives et de la variable cible

Plusieurs variables (rainfall, P, K, temperature, ph) présentent des points en dehors des moustaches. Comme ces variables ont des distributions multimodales liées aux différentes cultures, ces points ne correspondent probablement pas à des erreurs de saisie, mais à des valeurs normales pour certaines cultures ayant des besoins atypiques par rapport à la moyenne de l'ensemble du dataset. Pour cette raison, aucune ligne n'a été supprimée : cela aurait revenu à retirer des cultures entières sans justification solide. La variable cible yield_kg_ha, elle, ne présente aucune valeur aberrante.

3.3 Prétraitement

La variable label (nom de la culture) a été transformée avec la méthode du One-Hot Encoding : chaque culture devient une colonne binaire séparée (0 ou 1), plutôt qu'un simple numéro. Cela évite au modèle d'interpréter, à tort, un ordre ou une distance entre les cultures, qui n'en ont pas.

Les données ont ensuite été séparées en variables explicatives (X) et variable cible ($y = \text{yield_kg_ha}$), puis réparties en un ensemble d'entraînement (1760 lignes, 80 %) et un ensemble de test (440 lignes, 20 %), avec une graine aléatoire fixe (random_state = 42) pour que le découpage soit reproductible.

4. Modèles utilisés

Deux modèles de régression ont été comparés, conformément aux consignes du sujet :

- Régression Linéaire (linear_regression) : modèle simple qui cherche une relation linéaire entre les variables d'entrée et le rendement. Sert de référence (baseline).
- Random Forest Regressor (random_forest_regressor) : modèle plus complexe qui combine 100 arbres de décision ($n_estimators = 100$) et fait la moyenne de leurs prédictions. Il est capable de capturer des relations non linéaires.

Les deux modèles ont été entraînés sur les mêmes données d'entraînement, puis évalués sur le même ensemble de test, pour permettre une comparaison directe.

5. Résultats obtenus

Les résultats ont été mesurés avec trois métriques : le MAE (erreur moyenne en kg/ha), le RMSE (erreur qui pénalise davantage les grosses erreurs) et le R^2 (part de variance expliquée par le modèle, entre 0 et 1).

Modèle	MAE (kg/ha)	RMSE (kg/ha)	R^2
Régression Linéaire (baseline)	155.69	197.81	0.9569
Random Forest Regressor	176.89	224.42	0.9446

Tableau 2 — Comparaison des deux modèles sur l'ensemble de test

Contrairement à ce que l'on pourrait attendre, la régression linéaire obtient de meilleurs résultats que le Random Forest sur les trois métriques. Ce résultat s'explique par la façon dont la variable cible a été construite : yield_kg_ha est une simple combinaison linéaire des variables d'entrée, donc la régression linéaire capture cette relation de façon quasi optimale. Le Random Forest, conçu pour repérer des relations complexes et non linéaires, ne trouve ici aucune complexité supplémentaire à exploiter, ce qui explique sa performance légèrement inférieure.

Le modèle final retenu pour la sauvegarde et l'interface Gradio est donc la régression linéaire.




Figure 5 — Prédictions des deux modèles comparées aux valeurs réelles

Les deux nuages de points restent proches de la diagonale de prédiction parfaite sur toute la plage de rendement. Le nuage du Random Forest est légèrement plus dispersé, ce qui confirme le RMSE plus élevé mesuré précédemment. Aucun des deux modèles ne présente de biais systématique (aucune zone où les prédictions seraient toujours au-dessus ou toujours en dessous des valeurs réelles).

6. Analyse des erreurs

Pour mieux comprendre le comportement du modèle retenu (régression linéaire), l'erreur moyenne a été calculée séparément pour chacune des 22 cultures.




Figure 6 — Erreur moyenne (MAE) par culture

L'erreur varie entre environ 120 kg/ha (papaya, la plus faible) et 201 kg/ha (pigeonpeas, la plus élevée), sans rupture brutale entre les cultures. Deux hypothèses ont été testées pour expliquer cet écart :

- Le niveau moyen ou la variabilité du rendement par culture : cette hypothèse ne se confirme pas (par exemple, papaya a une forte variabilité de rendement mais la plus petite erreur).
- La dispersion des variables d'entrée (N, P, K, pluie, humidité) par culture : cette hypothèse ne se confirme pas non plus clairement (papaya a la plus grande dispersion de pluviométrie mais la plus petite erreur).

Aucune des deux hypothèses simples testées n'explique clairement le classement des erreurs par culture. Ce résultat est présenté tel quel : il suggère que l'écart de performance entre cultures provient probablement d'une combinaison de facteurs (interactions entre variables, effet du bruit aléatoire ajouté lors de la simulation) plutôt que d'une cause unique identifiable.

7. Limites du projet

- Rendement simulé, non réel : la variable `yield_kg_ha` a été générée artificiellement, faute de donnée de rendement dans le dataset source. Les résultats du modèle doivent donc être lus comme un exercice pédagogique de bout en bout, pas comme une prédiction agronomique fiable.
- Poids arbitraires : les coefficients utilisés dans la formule de simulation (15, 10, 10, 5, 8) ne reposent pas sur une source agronomique précise.
- Absence de relation non linéaire réelle : la simulation étant construite de façon linéaire, la comparaison entre régression linéaire et Random Forest ne reflète pas nécessairement ce qui se passerait avec de vraies données de rendement, où des interactions plus complexes existent généralement entre le sol, le climat et la culture.
- Biais géographique : le dataset ne représente pas forcément toutes les régions du monde ; le modèle pourrait ne pas s'appliquer à des zones non représentées dans les données.
- Usage : ces prédictions ne doivent pas servir à des décisions agricoles ou financières réelles sans validation par un expert agronome.

8. Perspectives d'amélioration

- Remplacer la variable de rendement simulée par de vraies données de rendement agricole, si un jeu de données adapté devient disponible.
- Tester des modèles supplémentaires (XGBoost, régression polynomiale) pour comparer davantage d'approches.
- Approfondir l'analyse des erreurs par culture avec des méthodes d'interprétabilité (par exemple l'importance des variables) pour mieux comprendre les écarts observés en section 6.
- Ajouter une validation croisée (cross-validation) plutôt qu'un simple split train/test, pour une évaluation plus robuste.
- Élargir le dataset à d'autres régions géographiques pour réduire le biais identifié en section 7.

9. Conclusion

Ce projet a permis de construire un pipeline complet de machine learning, de l'exploration des données jusqu'au déploiement d'une interface de démonstration avec Gradio, en passant par la comparaison de deux modèles de régression. Le modèle retenu (régression linéaire) atteint un R^2 de 0.957 sur les données de test. La principale limite du projet reste l'absence de données de rendement réelles, compensée par une simulation transparente et documentée tout au long de ce rapport.